НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Факультет программной инженерии и компьютерной техники

Дисциплина: Математическая статистика

Расчетная графическая работа №1
Вариант 15

Выполнил студент:

Немыкин Ярослав Алексеевич

Группа P3222

Преподаватель:

Лосев Александр Сергеевич

г. Санкт-Петербург, 2026

1. Первичное описание выборки

Для анализа предоставлены выборки объемом n = 200.
Для каждой выборки были построены вариационные ряды, построены эмпирические функции распределения и построены гистограммы, приложение 1.
Для построения гистограмм были использованы следующие формулы для определения ширины интервала:
Правило Скотта: $h = 3.5Sn^{-1/3}$
Правило Фрида-Диакониса: $h = 2IQRn^{-1/3}$, где $IQR = q_{0.75} - q_{0.25}$
Правило Стерджесса: $k = 1 + [\log_2 n]$
ЭФР определяется как
$F_n(x) = \frac{v_n(x)}{n}$, где $v_n(x) -$ числоэлементоввыборки, меньших x

В таблице 1 приведены основные характеристики выборок X1, X2, X3

Характеристика	Формула	X1	X2	X3
$\bar{x}$, выборочное среднее	$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$	65.3419	43.9104	55.3681
S^2, смещенная дисперсия	$S^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})$	2875.8403	115.1246	405.9346
$\hat{\sigma}^2$, несмещенная дисперсия	$\hat{\sigma}^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})$	2890.2917	115.7031	407.9745
S , стандартное отклонение	$\sqrt{S^2}$	53.6269	10.7296	20.1478
$\hat{\sigma}$, стандартное отклонение	$\sqrt{\hat{\sigma}^2}$	53.7614	10.7565	20.1984
m_e, медиана	$\frac{x_{n/2} + x_{n/2+1}}{2}$	50.185	43.22	56.265
квантили	$x_{0.25}, x_{0.5}, x_{0.75}$	29.2575, 50.185, 82.885	37.6425, 43.22, 50.4125	37.87, 56.265, 71.37

Таблица 1

Описание формы распределения:
X1 – Видна правосторонняя асимметрия, имеется хвост в области больших значений, на 2-х из трех гистограммах хвост имеет промежутки без значений, что может говорить о выбросах
X2 – Распределение симметричное, виден 1 пик, на 2- диаграммах виден провал слева от пика, вблизи него
X3 – Распределение симметричное, выраженного пика не наблюдается

2. Предположение о виде закона распределения

X1 – Экспоненциальная, гистограмма показывает убывание частот с ростом значения, а ЭФР имеет типичную «вогнутую» форму. Также среднее заметно больше медианы, что подтверждает асимметрию. Наличие возможных выбросов в правом хвосте не противоречит экспоненциальной модели.
X2 – Нормальное распределение, среднее, медиана и мода близки друг к другу, что также указывает на симметрию. Гистограмма напоминает колокол, а ЭФР плавно возрастает с характерной S-образной формой. Локальный провал возле пика можно объяснить случайными флуктуациями выборки

X3 – Равномерное распределение, гистограмма выглядит относительно плоской, без ярко выраженных максимумов. Квантили расположены примерно равномерно, что также характерно для равномерного распределения, ЭФР близка к линейной функции

3. Оценивание параметров: метод моментов и метод максимального правдоподобия

В таблице 2 приведены оценки параметров методов моментов и максимального правдоподобия.

Выборка	Параметр	Формула	Метод моментов	Формула	Метод максимального правдоподобия
X1 (Exp)	$\hat{\lambda}$	$\frac{1}{S}$	0.01865	$\min\{x_1, \dots, x_n\}$	0.0195
	$\hat{c}$	$\bar{x} - \frac{1}{\hat{\lambda}}$	11.7150	$\frac{1}{\bar{x} - \hat{c}}$	14.08
X2 (Norm)	$\hat{a}$	$\bar{x}$	43.91035	$\bar{x}$	43.91035
	$\hat{\sigma}^2$	S^2	115.1246	S^2	115.1246
X3 (Unif)	$\hat{a}$	$\bar{x} - \sqrt{3S^2}$	20.47100	$\min\{x_1, \dots, x_n\}$	21.74
	$\hat{b}$	$\bar{x} + \sqrt{3S^2}$	90.2651	$\max\{x_1, \dots, x_n\}$	90.05

Таблица 2

Сравнение: Нормальное распределение полностью совпадает, по равномерному и экспоненциальному распределениям, метод максимального правдоподобия больше приближен к реальным значениям, т. к. опирается на экстремальные значения выборки.

4. Оценивание параметрической вероятности двумя способами

Порог $x_0 = \bar{x} + \hat{\sigma}$. Оценим P(X > x_0).
Эмпирически по доле наблюдений, превышающих x_0
И параметрически, подставив оценки параметров в теоретическую формулу модели.

Выборка	x_0	Эмпирическое P	Параметрическое P	Ошибка
X1 (Exp)	119.1033	0.11	0.1290	0.019
X2 (Norm)	54.6669	0.16	0.1587	0.013
X3 (Unif)	75.5665	0.205	0.2120	0.007

Таблица 3

Наилучшее согласие достигнуто для равномерного распределения (X3). Для X1 и X2 расхождения могут быть связаны с особенностями реальных данных и выбором порога x_0, который может не являться оптимальным для всех типов распределений. Процент расхождения всех оценок не выше 15%.

5. Оценка моментов по сгруппированной выборке

Возьмем длину интервалов по правилу Стерджеса, тогда их количество будет равно 9.
Оценки для сгруппированных выборок:

$$\widehat{X}_g = \frac{1}{n}\sum_{k=1}^{m} n_k \widehat{X}_k$$

$$\hat{\sigma}_g^2 = \frac{1}{n-1}\sum_{k=}^{m} n_k\left(\hat{X}_k - \hat{X}_g\right)^2$$

Выборка	Параметр	Точное	Параметр	Сгруппированное	Ошибка
X1 (Exp)	$\bar{x}$	65.3419	$\widehat{X_g}$	67.7781	3.7%
	$\hat{\sigma}^2$	2890.2917	$\hat{\sigma}_g{}^2$	2663.9981	7.8%
X2 (Norm)	$\bar{x}$	43.9104	$\widehat{X_g}$	43.8647	0.1%
	$\hat{\sigma}^2$	115.7031	$\hat{\sigma}_g{}^2$	114.2871	1.2%
X3 (Unif)	$\bar{x}$	55.3681	$\widehat{X_g}$	55.3637	0.007%
	$\hat{\sigma}^2$	407.9745	$\hat{\sigma}_g{}^2$	409.6312	0.4%

Таблица 4

Полученные данные отклоняются незначительно от точечных оценок, группировка верна. Единственное, что можно отметить — у X1 ошибка по дисперсии 7.8%, что уже ближе к заметной, но всё ещё находится в пределе нормы.

6. Доверительные интервалы

Зафиксируем уровень доверия $1 - \alpha = 0.95$
Асимптотический доверительный интервал для EX (по ЦПТ) по каждой выборке указан в таблице 5.

Асимптотический ДИ для EX:

$$EX \in \left(\bar{x} - z_{1-\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + z_{1\text{-}\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}}\right)$$

Выборка	Интервал
X1 (Exp)	[57.8910; 72.7928]
X2 (Norm)	[42.4197; 45.4011]
X3 (Unif)	[52.5687; 58.1675]

Таблица 5

Для выборки X2 посчитаем точные доверительные интервалы, результаты представлены в таблице 6.

$$\mu \in \left(\bar{x} - \mathrm{t}_{1-\alpha/2,\mathrm{n}\text{-}1}\frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + \mathrm{t}_{1\text{-}\alpha/2,\mathrm{n}\text{-}1}\frac{\hat{\sigma}}{\sqrt{n}}\right)$$

$$\sigma^2 \in \left(\frac{(n-1)\hat{\sigma}^2}{\chi^2_{1-\alpha/2}}, \frac{(n-1)\hat{\sigma}^2}{\chi^2_{\alpha/2}}\right)$$

Для μ при неизвестной σ^2	[42.4234; 45.3974]
Для σ^2	[96.7433;141.5176]

Таблица 6

Доверительный интервал — это интервальная оценка неизвестного параметра, построенная по выборочным данным. При многократном повторении выборки в $\gamma \cdot 100\%$ случаев построенный интервал накроет истинное значение параметра. Для полученных интервалов: мы ожидаем, что в 95% случаев математическое ожидание X1 будет в пределах от 57.8910 до 72.7928. Аналогично и для X2, X3.

Это не вероятность того, что параметр лежит в интервале, поскольку параметр — не случайная величина, а фиксированное неизвестное число.
Значит после построения конкретного интервала мы не можем сказать, что параметр попадает в него с вероятностью 0.95 — он либо попадает, либо нет.

7. Итоговый вывод

Для выборки X1 выбрана экспоненциальная модель с параметром $\lambda \approx 0.0195$ (по ММП), что отражает выраженную правостороннюю асимметрию данных.
Для X2 наилучшей оказалась нормальная модель с параметрами $\mu \approx 43.91$ и $\sigma^2 \approx 115.12$, при этом оценки методов совпали.
Для X3 выбрана равномерная модель с параметрами, близкими к границам выборки (по ММП), что согласуется с формой распределения.

Доверительные интервалы для математического ожидания во всех случаях получились достаточно узкими, особенно для X2 и X3, что говорит о высокой точности оценок. Для X1 интервал шире, что связано с большей вариативностью и асимметрией данных.

Практически это означает, что нормальная и равномерная модели хорошо описывают соответствующие выборки и дают стабильные оценки. Экспоненциальная модель также применима, но требует более осторожной интерпретации из-за возможных выбросов и большей неопределенности.

8. Дополнительное задание. Бимодальность и кластеризация

Гистограмма и ЭФР указаны в приложении 1.
На гистограмме явно выражены 2 пика – в районе 30 и 90. ЭФР имеет S-образный вид с двумя «ступеньками», что также указывает на неоднородность данных.
Распределение является бимодальным, что говорит о двух режимах работы.

Выборка была разделена на 2 кластера:

Кластер	$\bar{x}$	S^2	n
1	93.5906	42.3234	95
2	31.3474	46.0861	105

Таблица 7

Выборочное среднее для всей выборки равно 60.91295.

Общее среднее плохо описывает смесь двух режимов, так как не лежит ни в одном кластере, если опираться при прогнозировании на данную величину, мы получим картину, не соответствующую реальности. Например, в нашем случае в районе общего среднего значений не будет, судя по гистограммам общих данных и кластеров.
При наличии признаков бимодальности лучше всего проверять данные на наличие нескольких мод, чтобы не допускать ошибок.

Приложение 1. ЭФР и гистограммы

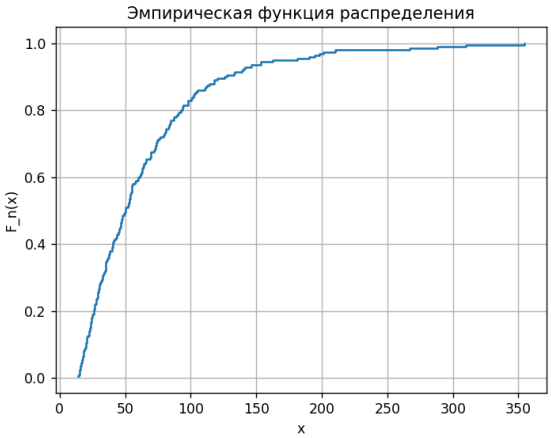

Рис. 1 ЭФР 1 выборки

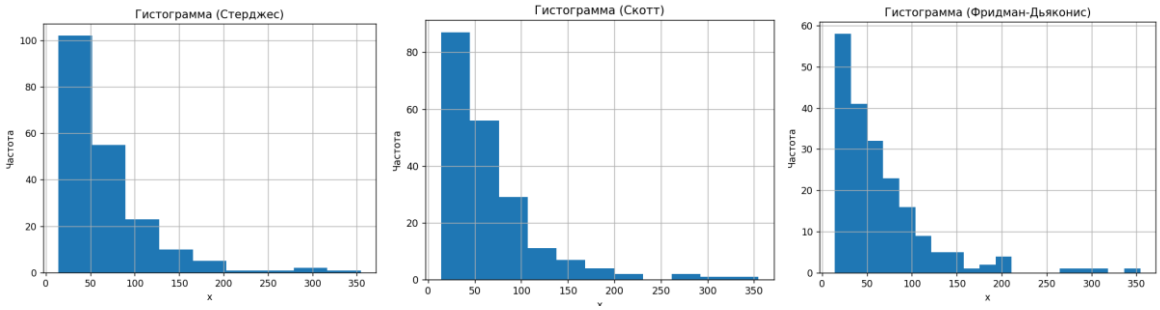

Рис. 2 гистограммы 1 выборки по различным правилам

Рис. 3 ЭФР 2 выборки

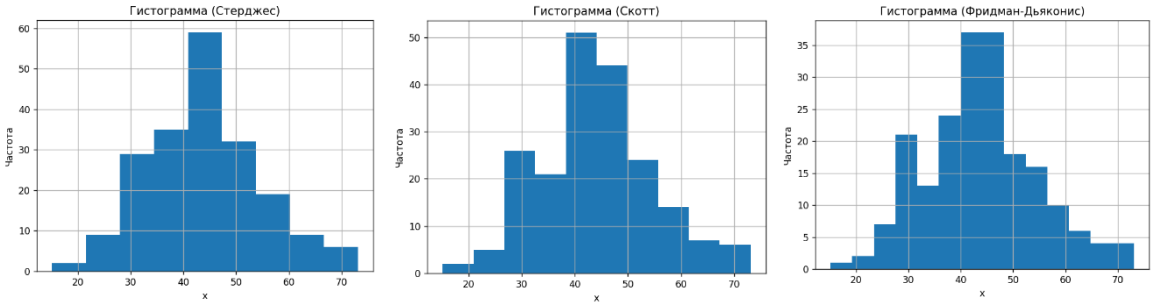

Рис. 4 гистограммы 2 выборки по различным правилам

Рис. 5 ЭФР 3 выборки

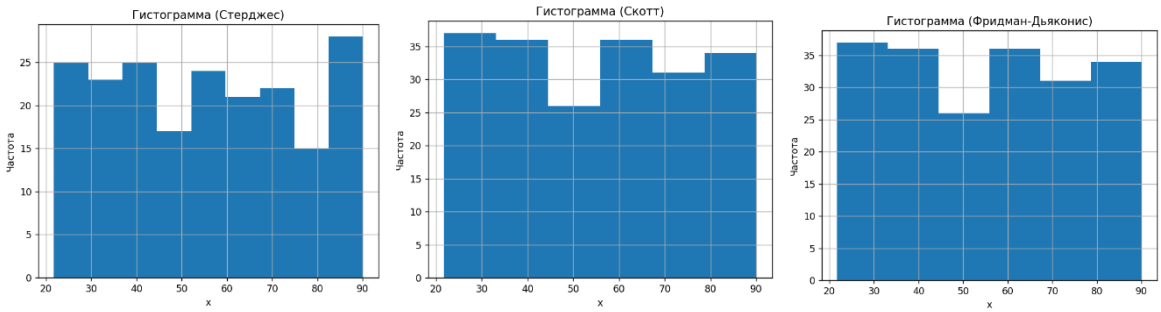

Рис. 6 гистограммы 3 выборки по различным правилам

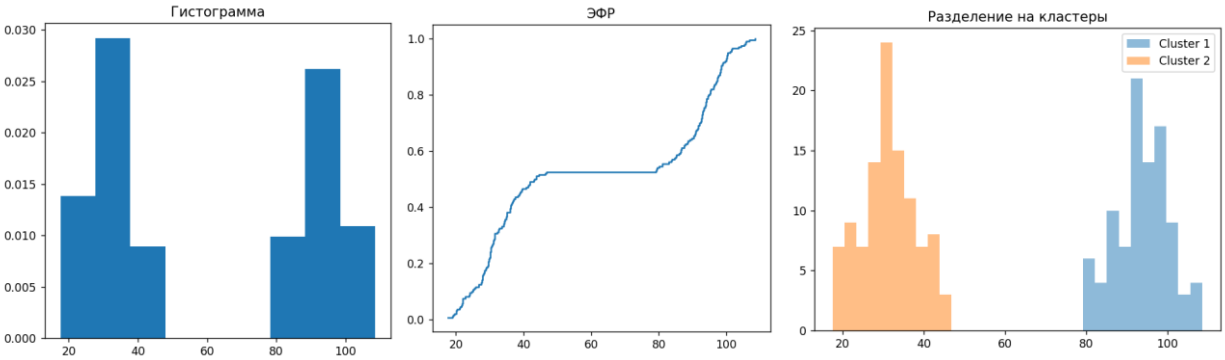

Рис. 7 гистограмма и ФСР и разделение на кластеры по 4 выборке